

基于逐笔成交的深度学习选股模型

华泰研究

2025 年 7 月 14 日 | 中国内地

深度研究

人工智能 93：挖掘逐笔成交数据中的 alpha

高频量价数据在量化投资中的重要性毋庸置疑。本文聚焦于逐笔成交数据的信息挖掘。由于数据量庞大，逐笔成交数据难以直接作为深度学习等选股模型的输入，需依赖特征工程提取有效信号。本文从资金流和事件驱动两个角度开展特征工程，采用深度学习模型捕捉数据规律，并提出模型优化方法，最后形成选股因子。

资金流模型：tick 线、成交量线等具有时间线外的增量信息

本研究基于逐笔成交数据，构造大小单、主动买卖等资金流特征。基线模型以个股过去 40 日的 30 分钟频资金流数据作为输入，采用 transformer 模型学习时序注意力，最终输出未来 10 日超额收益的预测。然而，传统时间线存在不匹配市场交易频率、时间序列统计特性差等缺陷。改进模型在时间线基础上，拓展出 tick 线、成交量线等增量数据，并利用 transformer 模型学习跨时间和跨 k 线的规律。实证结果表明，改进模型训练的选股因子在多项指标上均优于基线模型。样本空间为全 A 股，在 2017 年初至 2025 年 6 月底的回测期内（周频调仓），因子周度 RankIC 从 10.17%提升至 10.64%，多头年化超额收益率由 20.43%提升为 22.56%。

事件驱动模型：引入跨事件注意力可提升模型性能

逐笔成交数据中的重要成交事件（如大单、价格底部、价格顶部等）可能蕴含较为丰富的信息。本研究通过识别这些特殊事件，构造相应的事件特征。基线模型以个股过去 40 日的所有事件特征作为输入，采用 transformer 模型学习时序注意力，最终输出未来 10 日超额收益的预测。改进模型则采用分层注意力机制设计，第一层 transformer 仍学习时序注意力，第二层 transformer 捕捉跨事件的交叉注意力。回测结果显示，改进模型训练得到的因子在多项指标上均优于基线模型，周度 RankIC 从 9.94%提升至 10.01%，多头年化超额收益率由 20.06%提升为 22.38%。

改进资金流和事件驱动因子合成的融合因子表现更佳

将改进后的资金流和事件驱动选股因子等权合成，得到逐笔成交融合因子。在 2017 年初至 2025 年 6 月底的回测期内（周频调仓），该融合因子周度 RankIC 达 10.96%，多头年化超额收益率为 24.52%，表现优于单一因子。基于资金流因子、事件驱动因子和融合因子构建的中证 1000 增强组合，在相同回测期内年化超额收益率分别为 18.98%、17.24%和 19.92%，信息比率分别为 3.91、3.59 和 4.04。2025 年上半年，三者的超额收益分别为 5.57%、12.58%和 10.77%。

风险提示：基于逐笔成交数据的选股模型对市场微观结构的依赖较强，未来市场变化可能导致模型失效。Transformer 架构的复杂性可能增加训练和推理时间，并带来过拟合风险。本报告不涉及标的推荐。

林晓明

SAC No. S0570516010001
SFC No. BRB421

研究员

linxiaoming@htsc.com
+(86) 755 8208 0134

何康, PhD

SAC No. S0570520080004
SFC No. BRB318

研究员

hegang@htsc.com
+(86) 21 2897 2202


卢炯, CFA

SAC No. S0570123070272

联系人

lujiong@htsc.com
+(86) 755 8249 2388

融合因子的分层相对净值



资料来源：Wind，华泰研究



正文目录

研究导读	3
基于资金流的选股模型	5
基线模型	5
改进模型	6
因子测试	7
基于事件驱动的选股模型	9
基线模型	9
改进模型	10
因子测试	10
逐笔成交融合因子与指数增强	12
逐笔成交融合因子	12
因子相关性分析	12
指数增强	13
总结	15
风险提示	15
参考文献	15


研究导读

高频量价数据涵盖分钟k线、tick、逐笔成交、逐笔委托等类型，在量化投资中的重要性毋庸置疑。其中，逐笔成交数据作为最精细的交易明细记录，相比分钟线和tick数据具备更丰富的微观结构信息。然而，由于数据量庞大，逐笔成交数据难以直接作为深度学习等选股模型的输入，需依赖特征工程提取有效信号。

华泰金工前期报告《基于全频段量价特征的选股模型》（2023.12.8）中，利用逐笔成交数据构建了大单成交占比、主动买入占比等选股因子。本文将深入探讨逐笔成交的应用潜力，从资金流和事件驱动两个角度展开研究：

1. 基于逐笔成交数据，构造大小单、主动买卖等资金流特征，并在传统时间线基础上，拓展出tick线、成交量线等增量数据，最后利用transformer模型学习跨时间和跨k线的规律，形成资金流选股因子。
2. 识别逐笔成交数据中的大单、价格底部、价格顶部等重要成交事件，构造相应的事件特征，并使用transformer模型捕捉跨时间和跨事件的规律，形成事件驱动选股因子。

图表1：基于逐笔成交数据的深度学习选股模型



资料来源：Attention is all you need，华泰研究

研究发现，改进后的资金流和事件驱动选股因子合成的融合因子展现出较好的选股效果，该因子的周频调仓回测表现如下。


图表2：因子的IC值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
资金流因子_基线模型	10.17%	10.45%	0.97	83.98%	20.43%	3.58	80.39%	100.48%
资金流因子_改进模型	10.64%	10.57%	1.01	83.50%	22.56%	3.93	82.35%	97.10%
事件驱动因子_基线模型	9.94%	9.14%	1.09	86.89%	20.06%	3.29	84.31%	81.55%
事件驱动因子_改进模型	10.01%	9.21%	1.09	84.95%	22.38%	3.98	89.22%	90.36%
融合因子	10.96%	9.92%	1.11	85.44%	24.52%	4.18	85.29%	87.07%

注：回测期为2017/1/1~2025/6/30，周频调仓，计算RankIC采用T+1~T+6收盘价收益率，分10层，换手率为双边


资料来源：Wind，华泰研究

图表3：融合因子的分层组合相对净值



资料来源：Wind，华泰研究

图表4：融合因子的累计 RankIC



资料来源：Wind，华泰研究

基于资金流的选股模型

逐笔成交数据作为市场微观结构的核心载体，记录了成交时间、成交量、成交价格、成交金额、买方卖方编号、买卖方向标志等关键交易细节。本章将据此构造资金流特征，并运用深度学习优化选股模型。

图表5：逐笔成交数据示例（20230327，601688.SH）

	MDTime	TradeBuyNo	TradeSellNo	TradePrice	TradeQty	TradeMoney	TradeBSFlag
0	93000180	56554	227536	12.60	100.0	1260.0	2
1	93000180	68193	227536	12.60	2300.0	28980.0	2
2	93000420	229239	201286	12.61	600.0	7566.0	1
3	93000490	229861	201286	12.61	100.0	1261.0	1
4	93000800	230536	201286	12.61	200.0	2522.0	1
...	...	...	...	...	...	...	...
33106	145657250	11064682	10979090	12.61	2100.0	26481.0	1
33107	145657250	11064682	10991800	12.61	1500.0	18915.0	1
33108	145657250	11064682	10995620	12.61	16500.0	208065.0	1
33109	145657450	11065195	10995620	12.61	200.0	2522.0	1
33110	145657450	11065232	10995620	12.61	200.0	2522.0	1

资料来源：华泰数据中台，华泰研究

基线模型

本研究首先采用传统时间线（time bar）采样方法，将每个交易日的逐笔成交数据划分为 8 个 30 分钟等长区间，从中提取每根 k 线的价格、成交量、主动买卖量、大小单成交量等特征，具体特征定义如下。

图表6：资金流特征

特征类型	特征名称
价格类	开盘价、最高价、最低价、收盘价、均价
成交类	成交量、成交笔数
主动买卖类	主动买入量、主动卖出量
大小单类	大买单成交量、大卖单成交量、小买单成交量、小卖单成交量

资料来源：华泰研究

基线模型以个股过去 40 日的 30 分钟频资金流数据作为输入。为了使输入数据的分布具有较高的一致性，保证模型训练的稳定性，原始特征需进行时序和截面标准化。标准化后的数据通过常见的 transformer 模型，学习时序注意力，最终输出未来 10 日超额收益的预测。

图表7： 资金流基准模型及数据细节

特征和标签	特征 X: 个股过去 40 个交易日的 30 分钟频资金流数据。
	标签 y: 个股未来 10 个交易日 (T+1~T+11) 的收益率。
	特征预处理: 每个特征先进行时间序列标准化, 即将特征时间序列的每个值除以该序列的均值。再对每个特征进行截面 z-score 标准化。
	标签预处理: 对标签进行截面 z-score 标准化。
	样本内训练数据从 2014 年开始, 每 5 个交易日采样一次, 训练集和验证集依时间先后按照 4:1 的比例划分。
模型结构	Input Embedding: 输入嵌入。
	Positional Encoding: 位置编码。
	Multi-Head Attention: 多头注意力。
	Feed Forward: 全连接。
	Encoder: 每层包括多头注意力、全连接、残差连接、层标准化等。
	FC: 全连接, 输出预测。
模型其他参数	损失函数: 预测值与标签之间 IC 的相反数。
	batch_size: 5000。
	训练最大迭代轮数: 100, 早停轮数: 10。
	学习率: 0.001, 优化器: Adam。
	模型每年重新训练一次。

资料来源：华泰研究

改进模型

德普拉多在《金融机器学习》中提到, 尽管时间线在行业内和学术界应用最为广泛, 但可能存在两个问题: (1) 市场并不会以恒定的时间间隔对信息进行处理, 比如开盘后的活跃度远远高于其他时刻; (2) 时间采样序列的统计学特性极差, 如序列相关性、异方差性等。


为突破时间线的限制, 提高对逐笔成交数据的表征能力, 本研究拓展出 tick 线 (tick bar)、成交量线 (volume bar) 等多种类型的 k 线, 具体定义如下。每类 k 线的资金流特征定义与图表 6 保持一致。

图表8： K 线类型


K 线名称	K 线定义
时间线	按照固定时间间隔采样
Tick 线	按照相等成交笔数采样
成交量线	按照相等成交量采样
价格线	按照相等价格位移采样

资料来源：华泰研究

下图展示了不同 k 线的收盘价与成交量对比, 不难看出数据具有一定的差异性。

图表9： 不同 k 线的收盘价 (20230327, 601688.SH)


资料来源：华泰数据中台，华泰研究

图表10： 不同 k 线的成交量 (20230327, 601688.SH)

资料来源：华泰数据中台，华泰研究

改进模型以个股过去 40 日的不同类型 k 线的资金流数据作为输入，先通过第一层 transformer 学习时序注意力，再通过第二层 transformer 学习跨 k 线注意力，预测目标仍为未来 10 日超额收益。

图表11：资金流改进模型网络结构



资料来源：Attention is all you need，华泰研究

图表12：资金流改进模型及数据细节

特征和标签	特征 X：个股过去 40 个交易日的不同类型 k 线，k 线特征均为资金流数据。
	标签 y：个股未来 10 个交易日（T+1~T+11）的收益率。
	特征预处理：每个特征先进行时间序列标准化，即将特征时间序列的每个值除以该序列的均值。再对每个特征进行截面 z-score 标准化。
	标签预处理：对标签进行截面 z-score 标准化。
	样本内训练数据从 2014 年开始，每 5 个交易日采样一次，训练集和验证集依时间先后按照 4:1 的比例划分。
模型结构	Input Embedding：输入嵌入。
	Positional Encoding：位置编码。
	Multi-Head Attention：多头注意力。
	Feed Forward：全连接。
	Series Encoder：用于时序注意力，每层包括多头注意力、全连接、残差连接、层标准化等。
	Bars Encoder：用于 k 线注意力，每层包括多头注意力、全连接、残差连接、层标准化等。
	FC：全连接，输出预测。
模型其他参数	损失函数：预测值与标签之间 IC 的相反数。
	batch_size：5000。
	训练最大迭代轮数：100，早停轮数：10。
	学习率：0.001，优化器：Adam。
	模型每年重新训练一次。

资料来源：华泰研究

因子测试

为了减轻随机性干扰，本文的深度学习模型都用不同随机数种子训练三次，将三次的模型等权集成，作为最终的因子信号进行回测。因子测试方法如下：

1. 股票池：全 A 股，剔除 ST 股票，剔除每个截面期下一交易日停牌、涨停的股票。
2. 回测区间：2017/1/1~2025/6/30。
3. 调仓周期：周频，不计交易费用。
4. 测试方法：IC 值分析，因子分 10 层测试。

测试结果表明，改进模型在 RankIC 均值、RankICIR、TOP 组合超额收益率、TOP 组合信息比率、TOP 组合胜率、TOP 组合换手率等多项指标上表现均优于基线模型，且 RankIC 和多头收益的优势在近几年更为突出，说明多类型 k 线能够在传统时间线基础上贡献增量信息。


图表13：资金流因子的IC值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
资金流因子_基线模型	10.17%	10.45%	0.97	83.98%	20.43%	3.58	80.39%	100.48%
资金流因子_改进模型	10.64%	10.57%	1.01	83.50%	22.56%	3.93	82.35%	97.10%

注：回测期为 2017/1/1~2025/6/30，周频调仓，计算 RankIC 采用 T+1~T+6 收盘价收益率，分 10 层，换手率为双边


资料来源：Wind，华泰研究

图表14：资金流因子的 TOP 组合相对净值




资料来源：Wind，华泰研究

图表15：资金流因子的累计 RankIC



资料来源：Wind，华泰研究

图表16：资金流因子（改进模型）的分层组合相对净值



注：回测期为 2017/1/1~2025/6/30

资料来源：Wind，华泰研究

基于事件驱动的选股模型

逐笔成交数据中的重要成交事件可能蕴含较为丰富的信息。本章将构造事件驱动特征，并运用深度学习优化选股模型。

基线模型

本研究根据逐笔成交数据，识别出大单、价格顶部、价格底部等多类重要事件，具体事件定义如下。

图表17：事件类型

事件类型	事件定义
大单	最大的 1% 笔成交单
大买单	最大的 1% 笔主动买入单
大卖单	最大的 1% 笔主动卖出单
价格顶部	位于最高价的成交单
价格底部	位于最低价的成交单

资料来源：华泰研究

针对每类事件，构造多维特征指标，以捕捉市场参与者的异常交易行为，特征定义如下。

图表18：事件特征

特征名称	特征定义
volume_perc	事件成交量占全天成交量的比例
active_buy_perc	事件主动买入成交量占比
active_sell_perc	事件主动卖出成交量占比
vwap	事件均价与全天均价的比值
corr_volume_price	事件成交量与成交价的相关性

资料来源：华泰研究

为了保证模型训练的稳定性，首先需要对特征进行预处理，包括中位数去极值、行业市值中性化、截面 z-score 标准化、缺失值填充等。基线模型以个股过去 40 日的所有事件特征作为输入，采用 transformer 模型学习时序注意力，最终输出未来 10 日超额收益的预测。

图表19：事件驱动基准模型及数据细节


特征和标签	特征 X：个股过去 40 个交易日的事件特征。 标签 y：个股未来 10 个交易日（T+1~T+11）的收益率。 特征预处理：对每个特征进行中位数去极值、行业市值中性化、截面 z-score 标准化、缺失值填充。 标签预处理：对标签进行截面 z-score 标准化。 样本内训练数据从 2014 年开始，每 5 个交易日采样一次，训练集和验证集依时间先后按照 4:1 的比例划分。
模型结构	Input Embedding：输入嵌入。 Positional Encoding：位置编码。 Multi-Head Attention：多头注意力。 Feed Forward：全连接。 Encoder：每层包括多头注意力、全连接、残差连接、层标准化等。 FC：全连接，输出预测。 损失函数：预测值与标签之间 IC 的相反数。
模型其他参数	batch_size：5000。 训练最大迭代轮数：100，早停轮数：10。 学习率：0.001，优化器：Adam。 模型每年重新训练一次。

资料来源：华泰研究

改进模型

基线模型虽然能捕捉事件的时间演变规律，但忽略了不同类型事件之间的内在关联。为突破这一局限，改进模型采用分层注意力机制设计，第一层 transformer 仍学习时序注意力，第二层 transformer 捕捉跨事件的交叉注意力。

图表20：事件驱动改进模型网络结构



资料来源：Attention is all you need，华泰研究

图表21：事件驱动改进模型及数据细节

特征和标签	特征 X：个股过去 40 个交易日的事件特征。
	标签 y：个股未来 10 个交易日（T+1~T+11）的收益率。
	特征预处理：对每个特征进行中位数去极值、行业市值中性化、截面 z-score 标准化、缺失值填充。
	标签预处理：对标签进行截面 z-score 标准化。
	样本内训练数据从 2014 年开始，每 5 个交易日采样一次，训练集和验证集依时间先后按照 4:1 的比例划分。
模型结构	Input Embedding：输入嵌入。
	Positional Encoding：位置编码。
	Multi-Head Attention：多头注意力。
	Feed Forward：全连接。
	Series Encoder：用于时序注意力，每层包括多头注意力、全连接、残差连接、层标准化等。
	Events Encoder：用于事件注意力，每层包括多头注意力、全连接、残差连接、层标准化等。
	FC：全连接，输出预测。
模型其他参数	损失函数：预测值与标签之间 IC 的相反数。
	batch_size：5000。
	训练最大迭代轮数：100，早停轮数：10。
	学习率：0.001，优化器：Adam。
	模型每年重新训练一次。

资料来源：华泰研究

因子测试

改进模型在 RankIC 均值、TOP 组合超额收益率、TOP 组合信息比率、TOP 组合胜率表现均优于基线模型，说明引入跨事件注意力能够提升模型预测性能。


图表22：事件驱动因子的 IC 值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
事件驱动因子_基线模型	9.94%	9.14%	1.09	86.89%	20.06%	3.29	84.31%	81.55%
事件驱动因子_改进模型	10.01%	9.21%	1.09	84.95%	22.38%	3.98	89.22%	90.36%

注：回测期为 2017/1/1~2025/6/30，周频调仓，计算 RankIC 采用 T+1~T+6 收盘价收益率，分 10 层，换手率为双边


资料来源：Wind，华泰研究

图表23：事件驱动因子的 TOP 组合相对净值




资料来源：Wind，华泰研究

图表24：事件驱动因子的累计 RankIC



资料来源：Wind，华泰研究

图表25：事件驱动因子（改进模型）的分层组合相对净值



注：回溯期为 2017/1/1~2025/6/30

资料来源：Wind，华泰研究

逐笔成交融合因子与指数增强

逐笔成交融合因子

将改进后的资金流和事件驱动选股因子等权合成，得到逐笔成交融合因子。回测结果表明，融合因子在 RankIC 均值、RankICIR、RankIC>0 占比、TOP 组合超额收益率、TOP 组合信息比率等指标上均有提升，同时 TOP 组合换手率有所下降。


图表26：因子的 IC 值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
资金流因子_改进模型	10.64%	10.57%	1.01	83.50%	22.56%	3.93	82.35%	97.10%
事件驱动因子_改进模型	10.01%	9.21%	1.09	84.95%	22.38%	3.98	89.22%	90.36%
融合因子	10.96%	9.92%	1.11	85.44%	24.52%	4.18	85.29%	87.07%

注：回测期为 2017/1/1~2025/6/30，周频调仓，计算 RankIC 采用 T+1~T+6 收盘价收益率，分 10 层，换手率为双边


资料来源：Wind，华泰研究

图表27：不同类型因子的分层组合相对净值



资料来源：Wind，华泰研究

图表28：不同类型因子的累计 RankIC



资料来源：Wind，华泰研究

因子相关性分析

相关性分析显示，资金流因子与事件驱动因子相关性为 0.66，说明两者存在信息互补。此外融合因子呈现反转、低流动性、高 beta、低估值等风格暴露。

图表29：使用不同特征集训练因子间的相关性

	资金流因子_改进模型	事件驱动因子_改进模型	融合因子
资金流因子_改进模型		0.66	0.91
事件驱动因子_改进模型	0.66		0.91
融合因子	0.91	0.91	

资料来源：Wind，华泰研究

图表30：使用不同特征集训练因子与常见风险因子的相关性

	动量	市值	成交金额	换手率	beta	账面市值比
资金流_改进模型	-0.15	0.04	-0.25	-0.43	0.23	0.32
事件驱动_改进模型	-0.18	-0.08	-0.37	-0.41	0.21	0.18
融合因子	-0.17	-0.02	-0.33	-0.44	0.23	0.26

资料来源：Wind，华泰研究

指数增强

分别使用改进后的资金流因子、事件驱动因子和融合因子，构建中证 1000 指数增强组合，测试方法如下表。为降低调仓时点选择带来的偏差，对每个因子采用相邻 5 个交易日作为调仓起始日，构建 5 条独立调仓路径的组合，最终取回测结果的均值。这种方法类似于日频调仓，但总换手率基本保持不变。


图表31：中证 1000 增强组合构建细节

优化目标	最大化预期收益
成分股权重约束	不低于 80%
个股权重偏离上限	0.8%
风格因子约束	行业暴露<0.02, barra 暴露<0.3
换手率约束	周双边换手率上限为 30%
调仓频率和交易成本	5 日调仓，调仓当日以 vwap 价格成交，交易成本双边千分之四
调仓路径	采用相邻 5 个交易日作为调仓起始日，构建 5 条独立调仓路径的组合，取回测均值

资料来源：华泰研究

在 2017 年初至 2025 年 6 月底的回测期内，基于资金流因子、事件驱动因子和融合因子构建的中证 1000 增强组合，在相同回测期内年化超额收益率分别为 18.98%、17.24%和 19.92%，信息比率分别为 3.91、3.59 和 4.04，融合因子优于单一因子构建的组合。2025 年上半年，三者的超额收益分别为 5.57%、12.58%和 10.77%。

图表32：不同类型因子的中证 1000 增强组合超额收益



注：回测期为 2017/1/1~2025/6/30

资料来源：Wind，华泰研究

图表33：不同类型因子的中证 1000 增强组合回测绩效

	年化收益率	年化波动率	夏普比率	最大回撤	年化超额收 益率	年化跟踪误 差	超额收益最 大回撤	信息比率Calmar 比率	相对基准月 胜率	调仓双边换 手率
资金流因子_改进模型	14.79%	24.14%	0.61	38.02%	18.98%	4.86%	4.94%	3.91	3.84	83.33%
事件驱动因子_改进模型	13.10%	24.18%	0.54	35.11%	17.24%	4.81%	5.34%	3.59	3.23	85.29%
融合因子	15.70%	24.15%	0.65	36.81%	19.92%	4.94%	4.76%	4.04	4.18	88.24%
中证 1000	-3.65%	24.22%	-0.15	52.11%						

注：回测期为 2017/1/1~2025/6/30

资料来源：Wind，华泰研究

图表34：不同类型因子的中证1000增强组合逐年收益率

	2017 年收益率	2018 年收益率	2019 年收益率	2020 年收益率	2021 年收益率	2022 年收益率	2023 年收益率	2024 年收益率	2025 年收益率
资金流因子_改进模型	4.74%	-18.04%	50.81%	39.78%	50.94%	-10.23%	0.01%	11.77%	12.26%
事件驱动因子_改进模型	-3.75%	-20.59%	51.54%	36.65%	37.91%	-9.00%	4.48%	10.22%	19.27%
融合因子	2.09%	-18.02%	51.27%	41.28%	47.31%	-7.11%	1.49%	12.48%	17.46%
中证1000	-18.49%	-36.87%	25.67%	19.39%	20.52%	-21.58%	-6.28%	1.20%	6.69%

注：回测期为 2017/1/1~2025/6/30

资料来源：Wind，华泰研究

总结

高频量价数据在量化投资中的重要性毋庸置疑。本文聚焦于逐笔成交数据的信息挖掘。由于数据量庞大，逐笔成交数据难以直接作为深度学习等选股模型的输入，需依赖特征工程提取有效信号。本文从资金流和事件驱动两个角度开展特征工程，采用深度学习模型捕捉数据规律，并提出模型优化方法，最后形成选股因子。

资金流模型：tick 线、成交量线等具有时间线外的增量信息。本研究基于逐笔成交数据，构造大小单、主动买卖等资金流特征。基线模型以个股过去 40 日的 30 分钟频资金流数据作为输入，采用 transformer 模型学习时序注意力，最终输出未来 10 日超额收益的预测。然而，传统时间线存在不匹配市场交易频率、时间序列统计特性差等缺陷。改进模型在时间线基础上，拓展出 tick 线、成交量线等增量数据，并利用 transformer 模型学习跨时间和跨 k 线的规律。实证结果表明，改进模型训练的选股因子在多项指标上均优于基线模型。样本空间为全 A 股，在 2017 年初至 2025 年 6 月底的回测期内（周频调仓），因子周度 RankIC 从 10.17% 提升至 10.64%，多头年化超额收益率由 20.43% 提升为 22.56%。

事件驱动模型：引入跨事件注意力可提升模型性能。逐笔成交数据中的重要成交事件（如大单、价格底部、价格顶部等）可能蕴含较为丰富的信息。本研究通过识别这些特殊事件，构造相应的事件特征。基线模型以个股过去 40 日的所有事件特征作为输入，采用 transformer 模型学习时序注意力，最终输出未来 10 日超额收益的预测。改进模型则采用分层注意力机制设计，第一层 transformer 仍学习时序注意力，第二层 transformer 捕捉跨事件的交叉注意力。回测结果显示，改进模型训练得到的因子在多项指标上均优于基线模型，周度 RankIC 从 9.94% 提升至 10.01%，多头年化超额收益率由 20.06% 提升为 22.38%。

改进资金流和事件驱动因子合成的融合因子表现更佳。将改进后的资金流和事件驱动选股因子等权合成，得到逐笔成交融合因子。在 2017 年初至 2025 年 6 月底的回测期内（周频调仓），该融合因子周度 RankIC 达 10.96%，多头年化超额收益率为 24.52%，表现优于单一因子。基于资金流因子、事件驱动因子和融合因子构建的中证 1000 增强组合，在相同回测期内年化超额收益率分别为 18.98%、17.24% 和 19.92%，信息比率分别为 3.91、3.59 和 4.04。2025 年上半年，三者的超额收益分别为 5.57%、12.58% 和 10.77%。

风险提示

基于逐笔成交数据的选股模型对市场微观结构的依赖较强，未来市场变化可能导致模型失效。Transformer 架构的复杂性可能增加训练和推理时间，并带来过拟合风险。本报告不涉及标的推荐。

参考文献

- [1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [2] De Prado M L. Advances in financial machine learning[M]. John Wiley & Sons, 2018.

免责声明

分析师声明

本人，林晓明、何康，兹证明本报告所表达的观点准确地反映了分析师对标的证券或发行人的个人意见；彼以往、现在或未来并无就其研究报告所提供的具体建议或所表达的意见直接或间接收取任何报酬。

一般声明及披露

本报告由华泰证券股份有限公司（已具备中国证监会批准的证券投资咨询业务资格，以下简称“本公司”）制作。本报告所载资料是仅供接收人的严格保密资料。本报告仅供本公司及其客户和其关联机构使用。本公司不因接收人收到本报告而视其为客户。

本报告基于本公司认为可靠的、已公开的信息编制，但本公司及其关联机构（以下统称为“华泰”）对该等信息的准确性及完整性不作任何保证。

本报告所载的意见、评估及预测仅反映报告发布当日的观点和判断。在不同时期，华泰可能会发出与本报告所载意见、评估及预测不一致的研究报告。同时，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。以往表现并不能指引未来，未来回报并不能得到保证，并存在损失本金的可能。华泰不保证本报告所含信息保持在最新状态。华泰对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本公司不是 FINRA 的注册会员，其研究分析师亦没有注册为 FINRA 的研究分析师/不具有 FINRA 分析师的注册资格。

华泰力求报告内容客观、公正，但本报告所载的观点、结论和建议仅供参考，不构成购买或出售所述证券的要约或招揽。该等观点、建议并未考虑到个别投资者的具体投资目的、财务状况以及特定需求，在任何时候均不构成对客户私人投资建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。对依据或者使用本报告所造成的一切后果，华泰及作者均不承担任何法律责任。任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现，过往的业绩表现不应作为日后回报的预示。华泰不承诺也不保证任何预示的回报会得以实现，分析中所做的预测可能是基于相应的假设，任何假设的变化可能会显著影响所预测的回报。

华泰及作者在自身所知情的范围内，与本报告所指的证券或投资标的不存在法律禁止的利害关系。在法律许可的情况下，华泰可能会持有报告中提到的公司所发行的证券头寸并进行交易，为该公司提供投资银行、财务顾问或者金融产品等相关服务或向该公司招揽业务。

华泰的销售人员、交易人员或其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。华泰没有将此意见及建议向报告所有接收者进行更新的义务。华泰的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。投资者应当考虑到华泰及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。有关该方面的具体披露请参照本报告尾部。

本报告并非意图发送、发布给在当地法律或监管规则下不允许向其发送、发布的机构或人员，也并非意图发送、发布给因可得到、使用本报告的行为而使华泰违反或受制于当地法律或监管规则的机构或人员。

本报告版权仅为本公司所有。未经本公司书面许可，任何机构或个人不得以翻版、复制、发表、引用或再次分发他人（无论整份或部分）等任何形式侵犯本公司版权。如征得本公司同意进行引用、刊发的，需在允许的范围内使用，并需在使用前获取独立的法律意见，以确定该引用、刊发符合当地适用法规的要求，同时注明出处为“华泰证券研究所”，且不得对本报告进行任何有悖原意的引用、删节和修改。本公司保留追究相关责任的权利。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记。

中国香港

本报告由华泰证券股份有限公司制作，在香港由华泰金融控股（香港）有限公司向符合《证券及期货条例》及其附属法律规定的机构投资者和专业投资者的客户进行分发。华泰金融控股（香港）有限公司受香港证券及期货事务监察委员会监管，是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。在香港获得本报告的人员若有任何有关本报告的问题，请与华泰金融控股（香港）有限公司联系。

香港-重要监管披露

- 华泰金融控股（香港）有限公司的雇员或其关联人士没有担任本报告中提及的公司或发行人的高级人员。
- 有关重要的披露信息，请参华泰金融控股（香港）有限公司的网页 https://www.htsc.com.hk/stock_disclosure 其他信息请参见下方 “美国-重要监管披露”。

美国

在美国本报告由华泰证券（美国）有限公司向符合美国监管规定的机构投资者进行发表与分发。华泰证券（美国）有限公司是美国注册经纪商和美国金融业监管局（FINRA）的注册会员。对于其在美国分发的研究报告，华泰证券（美国）有限公司根据《1934年证券交易法》（修订版）第15a-6条规定以及美国证券交易委员会人员解释，对本研究报告内容负责。华泰证券（美国）有限公司联营公司的分析师不具有美国金融监管（FINRA）分析师的注册资格，可能不属于华泰证券（美国）有限公司的关联人员，因此可能不受 FINRA 关于分析师与标的公司沟通、公开露面和所持交易证券的限制。华泰证券（美国）有限公司是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。任何直接从华泰证券（美国）有限公司收到此报告并希望就本报告所述任何证券进行交易的人士，应通过华泰证券（美国）有限公司进行交易。

美国-重要监管披露

- 分析师林晓明、何康本人及相关人士并不担任本报告所提及的标的证券或发行人的高级人员、董事或顾问。分析师及相关人士与本报告所提及的标的证券或发行人并无任何相关财务利益。本披露中所提及的“相关人士”包括 FINRA 定义下分析师的家庭成员。分析师根据华泰证券的整体收入和盈利能力获得薪酬，包括源自公司投资银行业务的收入。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或不时会以自身或代理形式向客户出售及购买华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或其高级管理层、董事和雇员可能会持有本报告中所提到的任何证券（或任何相关投资）头寸，并可能不时进行增持或减持该证券（或投资）。因此，投资者应该意识到可能存在利益冲突。

新加坡

华泰证券（新加坡）有限公司持有新加坡金融管理局颁发的资本市场服务许可证，可从事资本市场产品交易，包括证券、集体投资计划中的单位、交易所交易的衍生品合约和场外衍生品合约，并且是《财务顾问法》规定的豁免财务顾问，就投资产品向他人提供建议，包括发布或公布研究分析或研究报告。华泰证券（新加坡）有限公司可能会根据《财务顾问条例》第32C条的规定分发其在华泰内的外国附属公司各自制作的信息/研究。本报告仅供认可投资者、专家投资者或机构投资者使用，华泰证券（新加坡）有限公司不对本报告内容承担法律责任。如果您是非预期接收者，请您立即通知并直接将本报告返回给华泰证券（新加坡）有限公司。本报告的新加坡接收者应联系您的华泰证券（新加坡）有限公司关系经理或客户主管，了解来自或与所述分发的信息相关的事宜。

评级说明

投资评级基于分析师对报告发布日后6至12个月内行业或公司回报潜力（含此期间的股息回报）相对基准表现的预期（A股市场基准为沪深300指数，香港市场基准为恒生指数，美国市场基准为标普500指数，台湾市场基准为台湾加权指数，日本市场基准为日经225指数，新加坡市场基准为海峡时报指数，韩国市场基准为韩国有价证券指数，英国市场基准为富时100指数），具体如下：

行业评级

增持：预计行业股票指数超越基准

中性：预计行业股票指数基本与基准持平

减持：预计行业股票指数明显弱于基准

公司评级

买入：预计股价超越基准15%以上

增持：预计股价超越基准5%~15%

持有：预计股价相对基准波动在-15%~5%之间

卖出：预计股价弱于基准15%以上

暂停评级：已暂停评级、目标价及预测，以遵守适用法规及/或公司政策

无评级：股票不在常规研究覆盖范围内。投资者不应期待华泰提供该等证券及/或公司相关的持续或补充信息

法律实体披露

中国: 华泰证券股份有限公司具有中国证监会核准的“证券投资咨询”业务资格, 经营许可证编号为: 91320000704041011J

香港: 华泰金融控股(香港)有限公司具有香港证监会核准的“就证券提供意见”业务资格, 经营许可证编号为: AOK809

美国: 华泰证券(美国)有限公司为美国金融业监管局(FINRA)成员, 具有在美国开展经纪交易商业业务的资格, 经营业务许可编号为: CRD#:298809/SEC#:8-70231

新加坡: 华泰证券(新加坡)有限公司具有新加坡金融管理局颁发的资本市场服务许可证, 并且是豁免财务顾问。公司注册号: 202233398E

华泰证券股份有限公司**南京**

南京市建邺区江东中路228号华泰证券广场1号楼/邮政编码: 210019

电话: 86 25 83389999/传真: 86 25 83387521

电子邮件: ht-rd@htsc.com

深圳

深圳市福田区益田路5999号基金大厦10楼/邮政编码: 518017

电话: 86 755 82493932/传真: 86 755 82492062

电子邮件: ht-rd@htsc.com

北京

北京市西城区太平桥大街丰盛胡同28号太平洋保险大厦A座18层/

邮政编码: 100032

电话: 86 10 63211166/传真: 86 10 63211275

电子邮件: ht-rd@htsc.com

上海

上海市浦东新区东方路18号保利广场E栋23楼/邮政编码: 200120

电话: 86 21 28972098/传真: 86 21 28972068

电子邮件: ht-rd@htsc.com

华泰金融控股(香港)有限公司

香港中环皇后大道中99号中环中心53楼

电话: +852-3658-6000/传真: +852-2567-6123

电子邮件: research@htsc.com

http://www.htsc.com.hk

华泰证券(美国)有限公司

美国纽约公园大道280号21楼东(纽约10017)

电话: +212-763-8160/传真: +917-725-9702

电子邮件: Huatai@htsc-us.com

http://www.htsc-us.com

华泰证券(新加坡)有限公司

滨海湾金融中心1号大厦, #08-02, 新加坡 018981

电话: +65 68603600

传真: +65 65091183

©版权所有2025年华泰证券股份有限公司